UVM

UNIVERSIDAD VIÑA DEL MAR

Correlación Lineal

Probabilidades y Estadística

Regresión

Al trabajar con dos variables, naturalmente surge la pregunta acerca de si hay, y cuál es, la relación entre ellas. Por ejemplo, cuando aumentan las temperaturas máximas, las ventas de bebidas también tienden a aumentar. ¿Es posible cuantificar esta relación? ¿Definirla de manera más precisa?

Hay distintos modelos que podemos usar, pero uno de los más comunes es el modelo de regresión lineal.

Modelos de Regresión

Un modelo de regresión es una función Y que intenta predecir el valor estimado de una variable respuesta, en función de uno o más predictores de interés, es decir, nos permite predecir el valor de Y, dados valores de la variable X.

En tal caso, diremos que:

Y = Variable dependiente.
X = Variable independiente, explicativa o predictora.

Modelos de Regresión

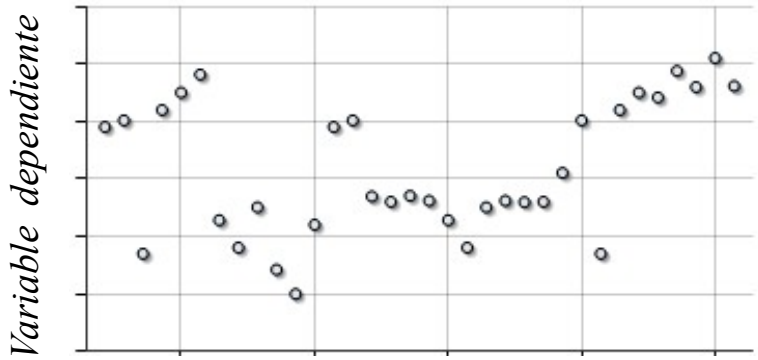
Existen diferentes tipos de modelos de regresión. Entre los modelos de regresión más conocidos están los siguientes:

- Modelo de regresión lineal.
- Modelo de regresión exponencial.
- Modelo de regresión logarítmica.

El modelo que convenga usar dependerá de la forma en que se relacionen las variables.

Gráfico de Dispersión

Es un diagrama en que los puntos representan valores de dos variables, una representada en el eje X y la otra en el eje Y. Su propósito es ayudar a ver la existencia y tipo de relación que puede existir entre las dos variables representadas.



Es importante conocer y distinguir distintos modelos funcionales, como por ejemplo:

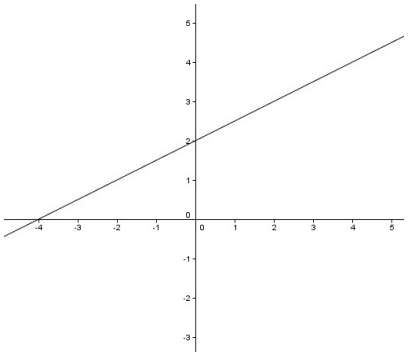


Gráfico de una función lineal

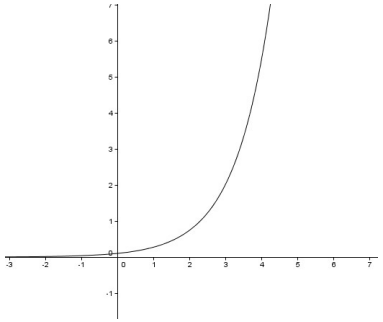


Gráfico de una función exponencial

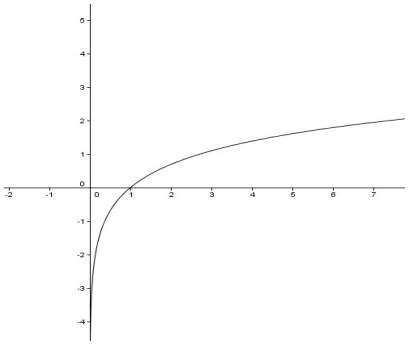


Gráfico de una función logarítmica

Covarianza Muestral

La covarianza muestral se utiliza para determinar si un cambio en una variable se asocia con un cambio en otra variable. Específicamente, la covarianza muestral nos dice si dos variables tienden a aumentar o disminuir juntas (**covarianza positiva**), o si una tiende a aumentar mientras la otra tiende a disminuir (**covarianza negativa**). Si la covarianza es cercana a **cero**, significa que no hay una relación lineal clara entre las dos variables.

Sea X e Y dos variables aleatorias cuantitativas, la covarianza muestral $Cov(X, Y)$ está definida como:

$$Cov(X, Y) = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

$$Cov(X, Y) = \frac{\sum x\, y - \frac{(\sum x)(\sum y)}{n}}{n - 1}$$

Ejercicio

Una empresa minera estudia el efecto de la potencia utilizada por un sistema de ventilación sobre la reducción de la concentración de material particulado en una zona de trabajo subterránea. Durante ocho pruebas controladas se obtuvieron los siguientes resultados:

a) Determine las variables dependiente e independiente

b) Calcule la covarianza entre las variables

Potencia del sistema (kW)	Reducción de material particulado ($\mu g/m^3$)
0.5	10
0.75	8
1.0	12
1.25	12
1.5	14
1.75	12
2.0	16
2.25	18

Ejercicio

Una empresa manufacturera desea analizar la relación entre el cumplimiento del programa de mantenimiento preventivo y las detenciones no programadas de sus áreas productivas. Para ello, seleccionó una muestra de 20 áreas y registró los siguientes resultados durante un trimestre:

- Identifique las dos variables estudiadas y señale cuál podría considerarse explicativa y cuál, variable respuesta.
- Calcule la covarianza muestral entre el porcentaje de cumplimiento del mantenimiento y las horas de detención no programada

Cumplimiento del mantenimiento (%)	Detenciones no programadas (h)
62	18
68	14
71	17
75	12
78	15
82	9
85	13
88	8
91	10
95	7
65	20
70	16
73	13
77	14
80	11

Correlación

Al estudiar la relación entre dos variables debemos ser capaces de responder las siguientes preguntas:

- ¿Las variables están relacionadas o no?
- ¿Es lineal esta relación y cuál es su grado?

Las preguntas anteriores pueden ser respondidas utilizando la medida de Coeficiente de Correlación Lineal de Pearson.

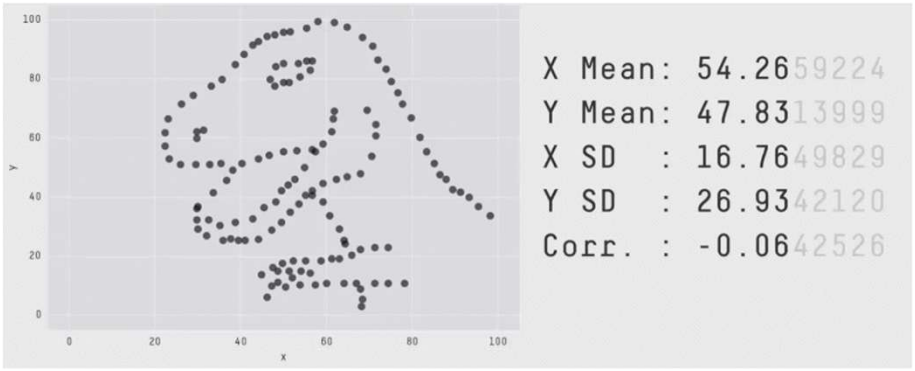
Coeficiente de Correlación de Pearson

El **Coeficiente de Correlación Lineal** entre dos variables (R_{xy}) muestra la linealidad de la relación entre las variables X e Y. En otras palabras, trata de responder la pregunta "¿Puedo representar a los datos mediante una línea recta?".

- Si $R_{xy} \approx 1$; La relación entre la variable X e Y es **lineal con pendiente positiva**.
- Si $R_{xy} \approx -1$; La relación entre la variable X e Y es **lineal con pendiente negativa**.
- Si $R_{xy} \approx 0$; No existe relación lineal entre la variable X e Y, aunque podría existir otro tipo de correlación (exponencial, logarítmica, etc.).

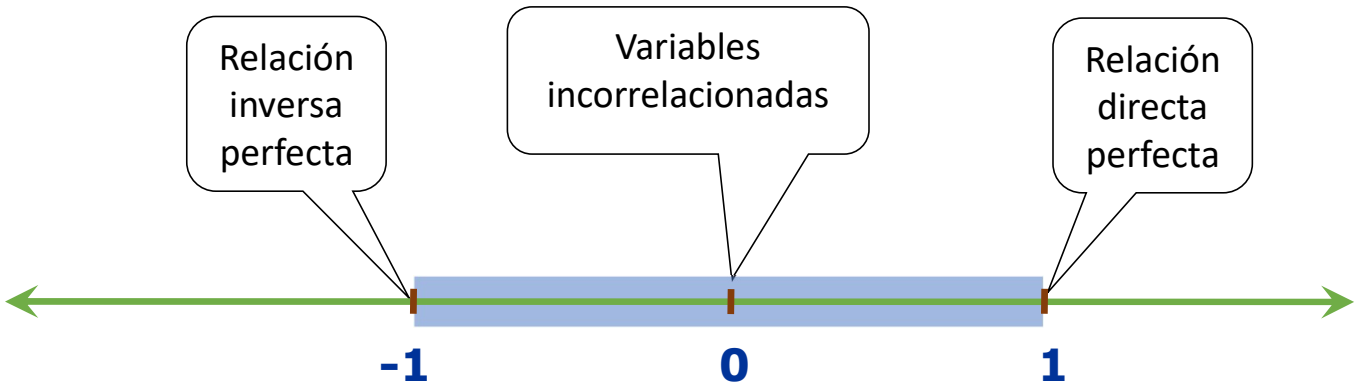
Coeficiente de Correlación de Pearson

Es importante usar este coeficiente junto con el diagrama de dispersión para tener una idea fidedigna de lo que ocurre con los datos. Por ejemplo, todos los conjuntos de datos tienen los mismos promedios, desviaciones estándar y correlación, pero claramente son muy distintos. Además, la baja correlación indica que no hay una relación lineal, pero visiblemente hay otras relaciones.



Coeficiente de Correlación de Pearson

- Es adimensional (no posee unidades de medida).
- Sólo toma valores en $[-1, 1]$.
- No hay correlación lineal si y sólo si $R_{xy} = 0$.
- Relación lineal perfecta entre dos variables $\Leftrightarrow R_{xy} = 1 \; o \; R_{xy} = -1$.
- Cuanto más cerca esté R_{xy} de 1 o -1, mayor será el grado de relación



Coeficiente de Correlación de Pearson

El coeficiente de correlación lineal de Pearson R_{xy} entre dos variables X e Y está definido como:

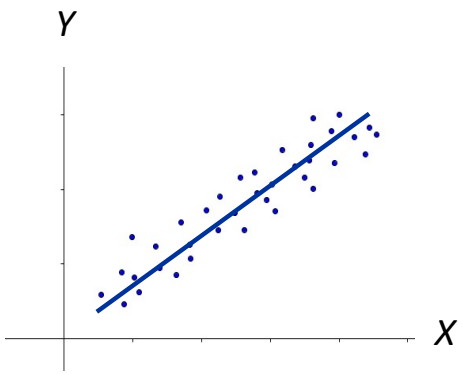
$$R_{xy} = \frac{Cov(X,Y)}{s_x s_y}$$

Donde s_x y s_y son las desviaciones estándar de X e Y , respectivamente.

Interpretación:

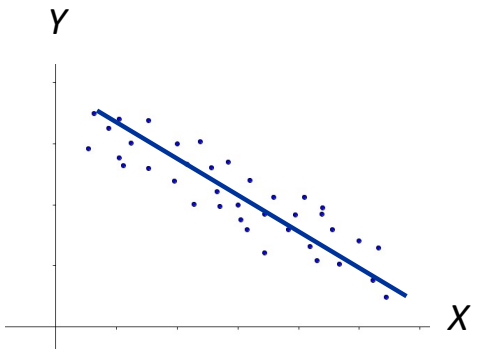
- 1 indica una **correlación positiva perfecta**.
- 0.7 a 0.9 (o −0.7 a −0.9) indica una **correlación fuerte**.
- 0.4 a 0.6 (o −0.4 a −0.6) indica una **correlación moderada**.
- 0.1 a 0.3 (o −0.1 a −0.3) indica una **correlación débil**.
- 0 indica que **no hay correlación lineal**.
- −1 indica una **correlación negativa perfecta**.

Ejemplo 1 En este caso el $R_{xy} \approx 1$.



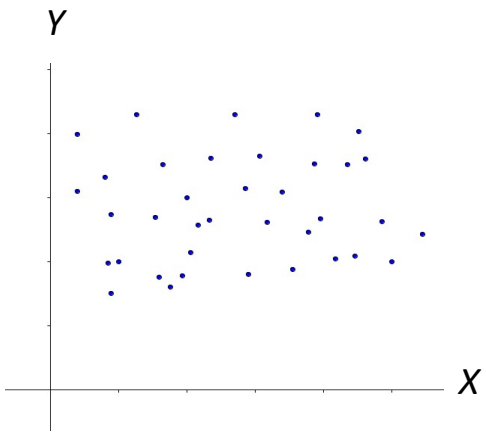
La nube de puntos puede aproximarse por una recta creciente. Por ejemplo, la altura (X) y el peso (Y) de los alumnos, ya que los alumnos más altos suelen pesar más.

Ejemplo 2 En este caso $R_{xy} \approx -1$.



La nube de puntos puede aproximarse por una recta decreciente. Por ejemplo, el peso de una carga (X) y el rendimiento de combustible (Y) de un camión, ya que un camión con mayor carga tiene menor rendimiento de combustible.

Ejemplo 3 En este caso el $R_{xy} \approx 0$.



No hay correlación lineal.

Ejercicio

Una empresa minera estudia el efecto de la potencia utilizada por un sistema de ventilación sobre la reducción de la concentración de material particulado en una zona de trabajo subterránea. Durante ocho pruebas controladas se obtuvieron los siguientes resultados:

a) Determine el coeficiente de correlación lineal de Pearson entre la potencia del sistema de ventilación y la reducción de material particulado.

b) Interprete el valor obtenido considerando la dirección y la intensidad de la relación lineal entre ambas variables.

Potencia del sistema (kW)	Reducción de material particulado ($\mu g/m^3$)
0.5	10
0.75	8
1.0	12
1.25	12
1.5	14
1.75	12
2.0	16
2.25	18

Ejercicio

En una planta piloto de tratamiento de aguas industriales se realizaron 12 ensayos para estudiar el efecto de la dosis de coagulante sobre distintas características del proceso. En cada ensayo se registraron las siguientes variables:

- Dosis de coagulante: cantidad de producto aplicada.
- Volumen de lodos: cantidad de residuos generados por el tratamiento.
- pH del efluente: nivel de acidez o alcalinidad después del tratamiento.
- Turbidez residual: concentración de partículas que permanecen en el agua tratada.

Los resultados fueron los siguientes:

Ensayo	Dosis de coagulante (mg/L)	Volumen de lodos (mL/L)	pH del efluente	Turbidez residual (NTU)
1	5	15	8,1	18,01
2	10	24	7,6	13,1
3	15	16	7,6	7,7
4	20	30	7,6	6,3
5	25	21	7,3	5,1
6	30	37	7,4	3,5
7	35	29	7,7	6,7
8	40	44	7,4	5,2
9	45	35	7,0	6,4
10	50	51	7,0	10,2
11	55	43	6,8	11,7
12	60	58	7,3	17,2

1. Calcule el coeficiente de correlación lineal de Pearson entre las siguientes variables.
    a. Dosis de coagulante y volumen de lodos.
    b. Dosis de coagulante y pH del efluente.
    c. Dosis de coagulante y turbidez residual.
2. Construya los siguientes gráficos de dispersión, utilizando la dosis de coagulante como variable independiente:
    a. Dosis de coagulante y volumen de lodos.
    b. Dosis de coagulante y pH del efluente.
    c. Dosis de coagulante y turbidez residual.
3. Clasifique las correlaciones obtenidas como positivas, negativas o nulas. Compare estos resultados con los patrones observados en los gráficos de dispersión.
4. Describa la forma, dirección e intensidad de la relación observada en cada gráfico de dispersion e interprete el coeficiente de correlación para cada uno de los casos.
5. Al considerar la dosis y la turbidez residual se obtiene $r = 0$. A partir únicamente de este resultado, un analista afirma que no existe relación entre ambas variables. ¿Es correcta esta conclusión? Justifique utilizando el gráfico de dispersión.